

**T.C.
ERCIYES ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ**

**EVİRİŞİMLİ SİNİR AĞLARI KULLANILARAK DÖKÜM
YÖNTEMİ İLE ÜRETİLEN DALGIÇ POMPA
ÇARKLARINDA HATA TESPİTİ**

**Hazırlayan
1030316015 Furkan GÜRBÜZ
1030322635 Furkan KILIÇASLAN
1030322687 Ali Can ÇOBAN**

**Danışman
Prof. Dr. Banu SOYLU**

**Endüstri Mühendisliği Bölümü
Uygulama Ödevi**

**Şubat 2021
KAYSERİ**

**T.C.
ERCIYES ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ**

**EVİRİŞİMLİ SİNİR AĞLARI KULLANILARAK DÖKÜM
YÖNTEMİ İLE ÜRETİLEN DALGIÇ POMPA
ÇARKLARINDA HATA TESPİTİ**

**Hazırlayan
1030316015 Furkan GÜRBÜZ
1030322635 Furkan KILIÇASLAN
1030322687 Ali Can ÇOBAN**

**Danışman
Prof. Dr. Banu SOYLU**

**Endüstri Mühendisliği Bölümü
Uygulama Ödevi**

**Şubat 2021
KAYSERİ**

BİLİMSEL ETİĞE UYGUNLUK

Bu çalışmadaki tüm bilgilerin, akademik ve etik kurallara uygun bir şekilde elde edildiğini beyan ederim. Aynı zamanda bu kural ve davranışların gerektirdiği gibi, bu çalışmanın özünde olmayan tüm materyal ve sonuçları tam olarak aktardığımı ve referans gösterdiğimi belirtirim.

Öğrenci Adı-Soyadı

İmza

Furkan Gürbüz

Furkan Kılıçaslan

Ali Can Çoban

ÖNSÖZ/TEŞEKKÜR

Bize çalışmalarımız süresince her türlü yardımı ve fedakârlığı sağlayan, danışmanımız Banu Soylu' ya teşekkür ederiz.

Furkan GÜRBÜZ

Furkan KILIÇASLAN

Ali Can ÇOBAN

Şubat 2021, KAYSERİ

EVİRİŞİMLİ SINIR AĞLARI KULLANILARAK DÖKÜM YÖNTEMİ İLE ÜRETİLEN DALGIÇ POMPA ÇARKLARINDA HATA TESPİTİ

Furkan GÜRBÜZ, Furkan KILIÇASLAN, Ali Can ÇOBAN

**Erciyes Üniversitesi, Mühendislik Fakültesi
Uygulama Ödevi, Şubat 2021
Danışman: Prof. Dr. Banu SOYLU**

ÖZET

Dalgıç pompa çarkı üretilirken döküm yöntemi kullanılır. Döküm, sıvı bir malzemenin genellikle istenen şekle sahip içi boş bir boşluk içeren bir kalıba döküldüğü ve daha sonra katılaşmaya bırakıldığı bir üretim sürecidir. Döküm yönteminden dolayı çeşitli kalite hataları oluşabilmektedir. Bu hataları tespit etmek için görüntü işleme tekniklerinden evrişimli sinir ağları (CNN) kullanılarak hata tespiti yapılmıştır. Ön işlemede standartlaştırma, kaydırma, yakınlaştırma, döndürme, çevirme ve parlaklık değişikliği gibi hazırlıklar yapılmıştır. Modelin hatalı ve hatasız pompa çarklarını sınıflandırması %97,34 başarı oranı ile sonuçlanmıştır.

Anahtar Kelimeler: Evrişimli sinir ağları, Hata Tespiti, Döküm Ürünü

DEFECT DETECTION OF SUBMERSIBLE PUMP IMPELLERS PRODUCED BY CASTING METHOD USING CONVOLUTIONAL NEURAL NETWORKS

Furkan GURBUZ, Furkan KILIÇASLAN, Ali Can ÇOBAN

**Erciyes University, Faculty of Engineering
Application Project, February 2021
Supervisor: Prof. Dr. Banu SOYLU**

ABSTRACT

The casting method is used while producing the submersible pump impeller. Casting is a manufacturing process in which a liquid material is poured into a mold, usually containing a hollow space of the desired shape, and then allowed to solidify. Various quality defects may occur due to the casting method. To detect these defects, defect detection was made using convolutional neural networks (CNN), one of the image processing techniques. Preparations such as standardization, panning, zooming, turning, rotating, and changing the brightness were made in the preprocessing phase. Classification of faulty and error-free pump impellers of the model resulted in a 97.34% success rate.

Keywords: Convolutional neural networks, Defect detection, Casting product

İÇİNDEKİLER

EVRIŞİMLİ SİNİR AĞLARI KULLANILARAK DÖKÜM YÖNTEMİ İLE ÜRETİLEN DALGIÇ POMPA ÇARKLARINDA HATA TESPİTİ

YÖNERGEYE UYGUNLUK SAYFASI.....	i
KABUL VE ONAY SAYFASI.....	ii
ÖNSÖZ/TEŞEKKÜR	iii
ÖZET.....	iv
ABSTRACT	v
İÇİNDEKİLER.....	vi
TABLolar LİSTESİ.....	vii
ŞEKİLLER LİSTESİ.....	viii
GİRİŞ	1
LİTERATÜR ÇALIŞMASI.....	3
PROBLEM TANIMI	7
YÖNTEM VE UYGULAMA.....	9
SONUÇ ve ÖNERİLER.....	12
KAYNAKÇA.....	13
ÖZGEÇMİŞ	15

TABLÖLAR LİSTESİ

Tablo 1. Modelin confusion matrisi	11
--	----

ŞEKİLLER LİSTESİ

Şekil 1. Çalışmada kullanılan döküm parçaların örnek görüntüsü	2
Şekil 2. Eğitim ve test kümesinde verilerin dağılımı.....	7
Şekil 3. Hatasız parça görüntüsü örneği.....	8
Şekil 4. Hatalı parçaların görüntülerinin örnekleri	8
Şekil 5. CNN'in mimari görüntüsü.....	10
Şekil 6. Model doğruluğu ve model kayıp fonksiyonu grafiği.....	11


GİRİŞ

Bu çalışmada görüntü işleme yöntemleri kullanılarak kalite hatalarının tespiti problemi ele alınmıştır. Kalite hataları, kalite kontrol operatörü tarafından muayene esnasında genellikle de görsel olarak tespit edilir. Kalite hatalarının tespit edilmesinde operatörün başarı oranı %70 tir. Bir kalite kontrol operatörünün işe odaklanma süresinin en fazla 30 dakika civarı olduğu bilimsel olarak tespit edilmiştir. Bu süreden sonra kalite kontrol operatöründe dikkat dağınıklığı başlar ve tam olarak odaklanamaz. Görüntü işleme teknikleriyle hata tespitinde ise %90 üzerinde başarı elde edilmektedir. Görüntü işleme yöntemleriyle kalite hata tespiti kumaş üretimi, demir-çelik üretimi, makine sanayi ve üretimin yapıldığı çoğu sektörde kullanılmaktadır. Bu sistemin en önemli girdileri yüksek çözünürlüklü bir kameradan elde edilen görüntüler ve bu görüntüleri işleyebilecek bir algoritmadır. Elde edilen görüntü saliseler içinde piksellere ayrılmakta, her piksele bir rakamsal değer atanmakta ve görüntü işleme algoritması ile farklılık (hata) tespiti sağlanmaktadır.

Güvenoğlu ve Bağırca'nın [1] çalışmasında kumaş verisinden hataları CNN kullanarak tespit etmiştir. Hata tespitinde kullanılan teknikler Lojistik regresyon, Karar ağaçları, K en yakın komşu, Naïve Bayes sınıflandırıcısı, Support Vector Machine (Destek Vektör Makinesi) olarak örnek verilebilir.

Ancak görüntü işleme tekniklerinin kullanmadan önce bir eğitim veri setinin oluşturulması ve gereksiz niteliklerden arındırılması gerekmektedir. Gereksiz niteliklerin indirgenmesi için temel bileşenler analizi (PCA), yerel ikili örüntü (LBP), gri düzey eş-oluşum matrisi (GLCM) yöntemleri vb. yöntemler kullanılmaktadır. Yıldız ve Buldu'nun [2] çalışmasında temel bileşenler analizini kullanarak öznitelik çıkarmıştır. Kaynar vd. [6] çalışmasında yerel ikili örüntü (LBP) ve gri düzey eş-oluşum matrisi (GLCM) yöntemleri kullanarak öznitelik çıkarmıştır.

Bu verinin eğitim kümesi oluşturulurken görüntü genellikle tek yönlü olarak alınmaktadır (Bkz. Şekil1a). Hatanın başka bir açıyla oluşması mümkündür (Bkz. Şekil1b). Ancak böyle bir örnek gerçekleşmediği için algoritma hata tespitini doğru olarak gerçekleştiremeyebilir. Bu yüzden modelde image data generator kullanılarak eğitim veri setinde 60 derecelik döndürme işlemi gerçekleştirilmiştir (Bkz. Şekil1b). Bu işlem diğer çalışmalarda shearlet dönüşümü [1] ve dalgacık dönüşümü [2] kullanılarak yapılmıştır.



Şekil 1. Çalışmada kullanılan döküm parçaların örnek görüntüsü

Bizim çalışmamızda döküm tekniği ile üretilen dalgıç pompa çarkının hatalı olanlarını görüntü işleme teknikleriyle tespit edilmesine odaklanıldı. Veri seti hazır olarak kaggle.com dan alındı. Dalgıç pompa çarkı ürünlerinin görüntü işleme tekniklerinden CNN kullanılarak hatalı ve hatasız olarak sınıflandırması tahmini gerçekleştirildi.

1. BÖLÜM

LİTERATÜR ÇALIŞMASI

Güvenoğlu ve Bağırca'nın [1] çalışmasında Shearlet dönüşümü ve yapay sinir ağları ile kumaş hatası tespiti yapılmıştır. Shearlet dönüşümünü bir resim karesinin sayısal görüntüsünü farklı açılardan dönüştürmek için kullanılmıştır. 1080×480 boyutunda belirlenen her bir kumaş yüzeyi görüntüsü farklı açılarda filtreleme işleminden geçirilirken 61 frekans dilimi kullanılmış ve böylece her bir görüntü için $1080 \times 480 \times 61$ ölçüsünde shearlet katsayı matrisleri hesaplanmıştır. Sonuç olarak KKS'den alınan her bir kumaş yüzeyi görüntüsünün analiz işlemlerinde kullanılmak üzere öznitelik vektör boyutu değeri $11 \times 11 + 1$ olarak bulunmuştur. YSA'nın eğitimi için Neural Network kullanılmıştır. Hatalı 1120 adet kot kumaş numunesi görüntüleri %80 eğitim, %20 test olarak bölünmüştür. Ayrıca 1120 adet görüntü haricinde 400 adet hatalı görüntü işleme konmayıp sonradan test için kullanılmıştır. Sonuç olarak yapılan kontrol işlemlerinde ortalama %94,25 hata tespit başarısının yakalandığı görülmüştür. Önerilen yöntemin geçerliliği ve elde edilen sonuçların doğruluğunu test etmek için K katlamalı çapraz doğrulama (K-Fold Cross Validation) yöntemi kullanılmıştır. Testler sonucunda ortalama doğruluk oranı %94.453 olarak elde edilmiştir.

Yıldız ve Buldu'nun [2] çalışmasında dalgacık dönüşümü, temel bileşen analizi ve yapay sinir ağları ile kumaş hatası tespiti yapılmıştır. Bu çalışmada kumaş kalite kontrol makinesi yardımı ile kot ve kaşe kumaşlara ait hatalı görüntülerin elde edilmesi sağlanmıştır. Gerçeklenen prototip sistem üzerine monte edilen kızılötesi ısıtıcı yardımıyla yüzey üzerindeki sıcaklık farkından yararlanılıp geliştirilen algoritma ile hata tespiti ve sınıflama işlemi yapılmıştır. Gri düzey eş oluşum matrisi ile ikili yani yan yana komşuluklar incelenmiştir. Görüntülerdeki ikili seviye limiti sekiz olarak seçilmiştir. Temel bileşen analizi bileşenlerinden faydalanılarak dönüşüm vektöründen gri seviyedeki görüntü çıkarımı yapılmıştır. Dalgacık dönüşümü yardımıyla görüntünün ayrıştırılması hedeflenmiştir. hatalı görüntüler üzerinde sıkıştırma işlemi yapılarak görüntülerdeki ayırt edici noktaların ortaya çıkarılması hedeflenmektedir. Uyarlamalı filtre olarak da

adlandırılan wiener filtre, optimizasyona elverişli ve yerel görüntü varyansının ayarlanmasında kullanılır. Wiener filtre ile verilen komşuluk değerine göre görüntü üzerindeki aykırı noktaların temizlendiği ve daha yumuşak görüntü geçişleri sağladığı ortaya çıkmaktadır. Görüntü işleme için K en yakın komşu algoritması kullanılmıştır. Kot ve kaşe için ayrı ayrı test için 60. eğitim için her bir hataya ait 10 görüntü kullanılmış ve sadece kot için hata denetiminde %100, sadece kaşe için hata denetiminde %95, kot ve kaşe beraber hata denetiminde %95 başarı oranı elde edilmiştir.

Şeker vd. [3] yaptığı çalışmada Autoencoder algoritması kullanarak kumaş hata tespiti yapmışlardır. Hata tespiti yapmak için ilk önce 1000 daha sonra 5000 örnek kullanmışlardır. Hata tespiti yaparken giriş ağ mimarisin de 2 tane autoencoder kullanılmıştır. Görüntünün çözünürlüğü fazla olduğu için çözünürlüğü düşürülmüştür. Giriş çözünürlüğü 25x25 alınmıştır. Sonuçları gözlemek için confusion matris kullanılmıştır. Bu matriste 40 hatalı üründen 9 ürünü hatasız, 60 hatasız üründe de 3 tane hatalı ürün çıkmıştır ve Başarı oranı %88 olduğu görülmüştür. Yapılan çalışmalar da hatalı örnek sayısı kısıtlı olduğundan, çalışmanın devamında daha çok sayıda ve farklı türde örneklerle testler yapılması planlanmaktadır. Bir başka planlanan çalışma ise örnekleri hatalı/hatasız olarak iki sınıfa ayırmak yerine; yırtık hatası, kaçık hatası, leke gibi hataları türlerine göre sınıflandırmayı sağlamaktır.

Feng vd. [4] çalışmasında derin aktif öğrenme iskeleti kullanarak bir otomatik hata tespit sistemi yapılmıştır. Bu sistemde hatayı tespit etme ve sınıflandırma için ResNet (Derin bir artık ağ) mimarisi kullanılmıştır. Aktif öğrenme iskeleti için verilerin ilk seti kullanılabilir hale gelir gelmez eğitilmiştir. Daha sonra ağın algılama performansını daha etkili bir şekilde iyileştirmek için etiketlenmemiş verilerin ve işin uzmanlarından gelen sorgu etiketleri bir araya getirilmiştir. Testler sonucunda ortalama doğruluk oranı %87,5 olarak elde edilmiştir.

Guan vd. [5] çalışmasında düz dokuma kumaşı için kusur tespiti yapmıştır. Orijinal RGB(KYM) görüntüler gri tonlamalı görüntülere dönüştürülmüştür ve gri seviye ayarlamasıyla daha da iyileştirilmiştir. Karşılaştırma amacıyla gürültüyü gidermek için

birkaç farklı filtreleme yöntemi kullanılmıştır ve ayarlanmış gri tonlamalı görüntülerin filtrelenmesi için ideal düşük geçiş filtresi seçilmiştir. VGG modeli kullanılarak filtrelenmiş görüntülerin tespiti ve sınıflandırılması için evrişimli sinir ağına dayalı derin öğrenme tekniği kullanılmıştır. Deneyler sonucunda 6 farklı hata sınıfına sahip 12000 eğitim kümesiyle eğitilen ve 2000 test kümesiyle test edilen model, %92,44 oranında doğruluk yakalamıştır.

Kaynar vd. [6] çalışmasında LBP-GLCM yöntemleri kullanarak kumaş hata tespiti yapmıştır. Tekstil verileri üzerinde yerel ikili örüntü ve gri düzey eş-oluşum matrisi öznitelik çıkarma yöntemleri uygulanarak elde edilen veri setleri yapay sinir ağları ile eğitilerek iki farklı model oluşturulmuş ve başarı oranları karşılaştırılmıştır. Veri setinde üç farklı kumaş sınıfına sahip 5 farklı hata sınıfı içeren 758 adet resim seçilmiştir. Daha sonra bu resimler her bir sınıfı en az bir kez içerecek şekilde 180 tanesi test, 578 tanesi eğitim kümesi olarak iki kümeye ayrılmıştır. LBP yöntemi %90,6, GLCM yöntemi ise %91,1 doğruluk oranı almıştır. GLCM yöntemi diğer modele göre daha az sayıda öznitelik çıkarmasına rağmen üstünlük sağlamıştır.

Zhen Wang ve Junfeng Jing'in [7] çalışmasında etiketleri belirtilmemiş eğitim verisi üzerinde çalışma yapılmıştır. Önerilen yöntem denetimli bir ağıdır ancak eğitim için manuel olarak etiketlenmiş örneklere ihtiyaç duymaz. Sahte bir örnek oluşturucu, yalnızca hatasız kumaş görüntüsüne ihtiyaç duyan hatalı görüntüyü simüle etmek için tasarlanmıştır. Önerilen model, sahte numunelerle eğitilmiş ve gerçek numunelerle doğrulanmıştır. Deneysel sonuçlar, yanlış verilerle eğitilen modelin yararlı olduğunu ve gerçek kumaş numunelerinde yüksek segmentasyon doğruluğu sağladığını göstermektedir. Ayrıca, kumaş görüntüsündeki arka plan piksel sayısı ile hatalı piksel sayısı arasındaki dengesizlik sorununu çözmek için bir kayıp fonksiyonu önerilmiştir. Bu yöntemin segmentasyon doğruluğunu ve algılama hızını doğrulamak için temsili kumaş numuneleri üzerinde kapsamlı deneyler yapılmıştır. Tespit etme süresini düşürmek için GPU kullanılmıştır. Modelin doğruluk oranı %98 olarak tespit edilmiştir. Yüksek hızlı bilgisayarlar ile endüstride bu model, gerçek zamanlı ve düşük maliyetli bir uygulama olabilecektir.

Wei vd. [8] çalışmasında bölgesel derin sinir ağı (RCNN) ile kumaş hata tespiti yapılmıştır. RCNN, derin sinir ağlarının (CNN) özelleştirilmiş halidir. Hatayı gözlemlerken hata merkezde olacak şekilde farklı boyutlarda görüntüler alınır ve

RCNN'ye eğitim verisi olarak gösterilir. Deneysel çalışmalar bölümünde 6 farklı hata tespit edilmiştir ve her hata için 135 görüntü çekilmiştir. Her görüntü 227x227 olacak şekilde piksellere ayrılmıştır. Bir görselin ortalama RCNN tarafından analiz zamanı 0,3 saniyedir. Bununla birlikte bazı farkı yaklaşımları karşılaştırılmıştır. Burada FCNN %96 doğruluk oranı ile diğerlerinden daha iyi performans vermiştir.

2. BÖLÜM


PROBLEM TANIMI

Dalgıç pompa çarkı üretilirken döküm yöntemi kullanılır. Döküm, sıvı bir malzemenin genellikle istenen şekle sahip içi boş bir boşluk içeren bir kalıba döküldüğü ve daha sonra katılaşmaya bırakıldığı bir üretim sürecidir. Döküm yönteminden dolayı çeşitli kalite hataları oluşabilmektedir. Dökümde hava delikleri, iğne delikleri, çapak, çekme hataları, kalıp malzemesi hataları, döküm metal hataları, metalürjik hatalar gibi birçok hata türü vardır.

Her üretim aşamasında olduğu gibi döküm üretilen bir proseste de hatalar istenmeyen bir şeydir. Bu hatalı ürünü çıkarmak için tüm endüstrinin kendi kalite kontrol departmanı vardır. Ancak asıl sorun, bu denetim işleminin manuel olarak yapılmasıdır. Çok zaman alan bir süreçtir ve insan hatası nedeniyle bu denetim % 100 doğru gerçekleşmeyebilir. Bu da tüm siparişin reddedilmesine neden olabilir.


Bu çalışmada görüntü işleme teknikleri kullanılarak kalite kontrol sürecinin otomatik hale getirilmesi ve bu problem için Evrişimli Sinir Ağı (CNN) ile sınıflandırma yönteminin kullanılması amaçlanmıştır.

Veri seti %10,7'si test ve %89,3'ü eğitim olarak ayrılmıştır. Eğitim veri setinde 3758 hatalı, 2875 hatasız olmak üzere bu iki sınıfa ait toplam 6633 görüntü bulunmaktadır. Test veri setinde 453 hatalı, 262 hatasız olmak üzere toplam 715 görüntü bulunmaktadır. Şekil 2'de sınıfların dağılımı verilmiştir. 0-hatasız, 1-hatalı olarak kodlanmıştır.




Şekil 2. Eğitim ve test kümesinde verilerin dağılımı

Şekil 3'te veri setinden alınan hatasız bir parçaya ait görüntü verilmiştir. Image Data Generator kullanılarak 244x244 boyutlarında sayısal bir matrise dönüştürülmüştür. Matrisin her elemanı temsil ettiği pikselin grilik tonunu göstermektedir.



Şekil 3. Hatasız parça görüntüsü örneği



Şekil 4. Hatalı parçaların görüntülerinin örnekleri

3. BÖLÜM

YÖNTEM VE UYGULAMA

Çalışmada Evrişimli Sinir Ağları (CNN) ile sınıflandırma yöntemi kullanılmıştır. Modelin doğruluğunu optimize etmek için de veri seti artırılmıştır. Bunun için keras kütüphanesinden image data generator kullanarak görüntüye döndürme, kaydırma işlemleri uygulandı.

Ön işleme kısmında eğitim veri setini 1/255 oranında standartlaştırıldı. 0,3 oranında kaydırma yoğunluğu, 0,3 oranında yakınlaştırma, dikey ve yatay olarak çevirme, 60 derece döndürme ve (0,4, 1,4) oranında parlaklık değişimi yapıldı. Batch size (parti yoğunluğu) 32, görüntü büyüklüğü 244x244, gri tonlu, ikili sınıflandırma içeren bir eğitim veri seti hazırlandı. Sınıflandırmada hatasız olan görüntüler için 0, hatalı olan görüntüler için 1 atamaları yapıldı. Test veri setinde ise 1/255 oranında normalleştirme, 244x244 olarak ayarlamalar yapıldı.

Model olarak Sequential kullanıldı. Kernel_size için 3x3 matris kullanıldı. Toplamda 7 katman oluşturuldu. Her katmandan sonra bir pooling işlemi gerçekleştirildi. Aktivasyon kodu olarak relu, padding için same kullanıldı. Çıkış fonksiyonundan önce flatten işlemi gerçekleştirildi. Çıkış aktivasyon kodu için sigmoid fonksiyonu seçildi. Loss fonksiyonu olarak binary_crossentropy kullanıldı. Epoch sayısı olarak 10 seçildi ve her epoch başına adım sayısı olarak 207 hesaplandı. Şekil 5'te CNN'in mimari görüntüsü verilmiştir.

```
Model: "sequential"
```

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 122, 122, 16)	160
max_pooling2d (MaxPooling2D)	(None, 61, 61, 16)	0
conv2d_1 (Conv2D)	(None, 61, 61, 32)	4640
max_pooling2d_1 (MaxPooling2D)	(None, 30, 30, 32)	0
conv2d_2 (Conv2D)	(None, 30, 30, 64)	18496
max_pooling2d_2 (MaxPooling2D)	(None, 15, 15, 64)	0
conv2d_3 (Conv2D)	(None, 15, 15, 128)	73856
max_pooling2d_3 (MaxPooling2D)	(None, 7, 7, 128)	0
conv2d_4 (Conv2D)	(None, 7, 7, 256)	295168
max_pooling2d_4 (MaxPooling2D)	(None, 3, 3, 256)	0
flatten (Flatten)	(None, 2304)	0
dense (Dense)	(None, 64)	147520
dropout (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 1)	65

```

Total params: 539,905
Trainable params: 539,905
Non-trainable params: 0

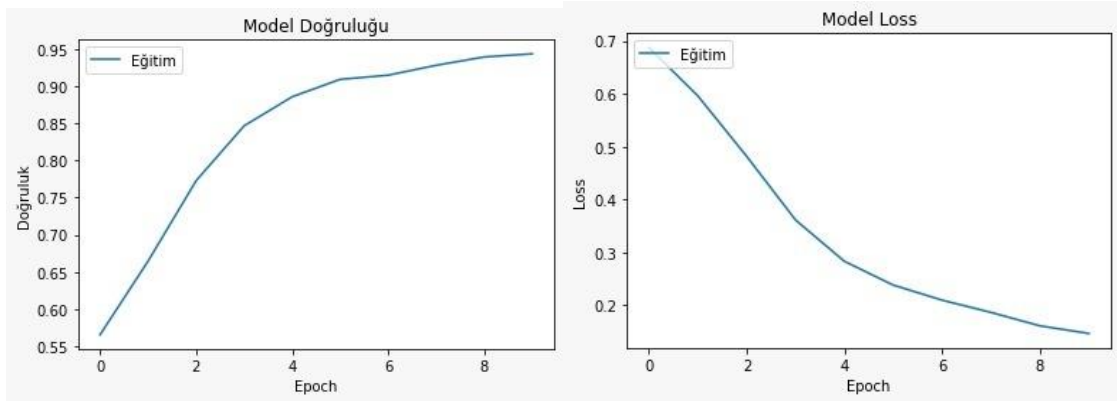
```

Şekil 5. CNN'in mimari görüntüsü

Modelimiz 262 hatasız görüntüden 250 tanesini doğru, 12 tanesini yanlış tahmin etmiştir. 453 hatalı görüntüden 7 tanesini yanlış, 446 tanesini doğru tahmin etmiştir (Bkz. Tablo1). Modelimizin doğruluk oranı %97,34'tür.

	Hatasız tahmin edilen	Hatalı tahmin edilen
Aslında hatasız olan	250	12
Aslında hatalı olan	7	446

Tablo1. Modelin confusion matrisi



Şekil 6. Model doğruluğu ve model kayıp fonksiyonu grafiği

Kayıp fonksiyonu grafiği, bir tahminci $f(x)$ ile gerçek y değeri arasındaki belirli bir miktar farkın model tarafından cezalandırılacağını temsil eder. Model doğruluğu grafiği, epoch başına modelin aldığı doğruluk oranını göstermektedir.

4. BÖLÜM

SONUÇ VE ÖNERİLER

Kalite hatalarının tespiti birçok işletme için önem arz etmektedir. Yapay zekâ uygulamaları ile bu işlem daha kolay ve hızlı hale gelmektedir. Bunun için hazırladığımız derin öğrenme modelimiz yavaş çalışmasına karşın oldukça iyi bir sonuç elde etmiştir. Kullanılan veri setinde yaklaşık 7000 görüntü bulunmaktadır. Modelin ön hazırlık, eğitim ve test işlemlerinin tamamlanma süresi yaklaşık 20 dakika almaktadır.

Modelin çalıştırıldığı sistemin özelliklerine bağlı olan bu süre iyi donanımlarla optimize edilebilir. Parametre değişiklikleri ile modelin mevcut doğruluk oranı artırılabilir. Farklı görüntüler ve açılar eklenerek modelin ezberlemesinin önüne geçilebilir.

KAYNAKÇA

1. GÜVENOĞLU, E., & BAĞIRGAN, M. (2019). Shearlet Dönüşümü ve Görüntü İşleme Teknikleri Kullanılarak Kot Kumaşlar Üzerinde Gerçek Zamanlı Hata Tespiti. *El-Cezeri Journal of Science and Engineering*, 6(3), 491-502.
2. Yıldız, K., & Buldu, A. Kumaş hata tespiti ve sınıflandırmada dalgacık dönüşümü ve temel bileşen analizi. *Pamukkale Üniversitesi Mühendislik Bilimleri Dergisi*, 23(5), 622-627.
3. Şeker, A., Peker, K. A., Yüksek, A. G., & Delibaş, E. (2016, May). Fabric defect detection using deep learning. In *2016 24th Signal Processing and Communication Application Conference (SIU)* (pp. 1437-1440). IEEE.
4. Feng, C., Liu, M. Y., Kao, C. C., & Lee, T. Y. (2017). Deep active learning for civil infrastructure defect detection and classification. In *Computing in civil engineering 2017* (pp. 298-306).
5. Guan, M., Zhong, Z., Rui, Y., Zheng, H., & Wu, X. (2019, September). Defect Detection and Classification for Plain Woven Fabric Based on Deep Learning. In *2019 Seventh International Conference on Advanced Cloud and Big Data (CBD)* (pp. 297-302). IEEE.
6. Kaynar, O., Görmez, Y., Işık, Y. E., & Demirkoparan, F. LBP-GLCM Yöntemleri ile Kumaş Hata Tespiti.
7. Wang, Z., & Jing, J. (2020). Pixel-wise fabric defect detection by CNNs without labeled training data. *IEEE Access*, 8, 161317-161325.
8. Wei, B., Hao, K., Tang, X. S., & Ren, L. (2018, June). Fabric defect detection based on faster RCNN. In *international conference on artificial intelligence on textile and apparel* (pp. 45-51). Springer, Cham.

VERİ SETİ

<https://www.kaggle.com/ravirajsinh45/real-life-industrial-dataset-of-casting-product>

ÖZGEÇMİŞ

Adı-Soyadı : Furkan Gürbüz

Doğum Yılı/Yeri : 1998/KAYSERİ

Eğitim

Ortaöğretim : Bünyan Fen Lisesi, KAYSERİ ,2016

Lisans : Erciyes Üniv., Endüstri Müh. Bölümü, Kayseri

Telefon : 05532719448

E-posta : 1030316015@erciyes.edu.tr

İlgilendiği Mesleki Konular: Proje Yönetimi, Yapay Zeka Üretim Planlama, Yalın İmalat, Kalite Kontrol

Bilgisayar Becerileri: Python, Minitab, C#, MSSQL, Java, Lingo, Arena, Cplex

Yaptığı Projeler: Dizi-Film internet sitesi veri tabanı tasarımı, Evrişimli sinir ağları ile döküm ürünlerinde hata tespiti

İş – Staj - Liderlik Deneyimi:

Kurs ve Sertifikalar: Deep Learning A-Z™| Python ile Derin Öğrenme

ÖZGEÇMİŞ

Adı-Soyadı : Furkan Kılıçaslan

Doğum Yılı/Yeri : 1999/İstanbul

Eğitim

Lise : Mehmetçik Anadolu Lisesi, İstanbul, 2017

Lisans : Erciyes Üniv., Endüstri Müh. Bölümü, Kayseri

Telefon : +905523381797

E-posta : 1030322635@erciyes.edu.tr

İlgilendiği Mesleki Konular: Yalın Üretim, Yapay Zekâ, Endüstri 4.0, Kalite

Bilgisayar Becerileri: Python, Minitab, SPSS, Tableau, SAP BI, MSSQL

Yaptığı Projeler: Derin Öğrenme ve Görüntü İşleme ile Kedi ve Köpek Resimlerinin Sınıflandırılması, Spam Maillerin Sınıflandırılması, Göğüs Kanseri Tümörünün Sınıflandırılması, Yapay Sinir Ağları ile Fiyat Tahmini

İş – Staj - Liderlik Deneyimi:

Kurs ve Sertifikalar: Digital Manufacturing & Design Technology, Data Analytics for Lean Six Sigma, Six Sigma Yellow Belt, Applied Data Science with Python, Python A-Z™: Veri Bilimi ve Machine Learning

ÖZGEÇMİŞ

Adı-Soyadı : Ali Can Çoban

Doğum Yılı/Yeri : 1996/Antalya

Eğitim

Lise : 75. Yıl Cumhuriyet Lisesi, 2015

Lisans : Erciyes Üniv., Endüstri Müh. Bölümü, Kayseri

Telefon : +905050779534

E-posta : 1030322687@erciyes.edu.tr

İlgilendiği Mesleki Konular: Proje Yönetimi, Lojistik

Bilgisayar Becerileri: Python, Logo Netsis

Yaptığı Projeler: Evrişimli sinir ağları(CNN) ile döküm ürünlerinde hata tespiti, Göğüs Kanseri Tümörünün Sınıflandırılması

İş – Staj - Liderlik Deneyimi:

Kurs ve Sertifikalar: Python A-Z™: Veri Bilimi ve Machine Learning, A2 İngilizce